ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ

ΣΧΟΛΗ ΤΕΧΝΟΛΟΓΙΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΕΠΙΚΟΙΝΩΝΙΩΝ

ΤΜΗΜΑ ΨΗΦΙΑΚΩΝ ΣΥΣΤΗΜΑΤΩΝ

ΠΡΟΓΡΑΜΜΑ ΜΕΤΑΠΤΥΧΙΑΚΩΝ ΣΠΟΥΔΩΝ

“ΠΛΗΡΟΦΟΡΙΑΚΑ ΣΥΣΤΗΜΑΤΑ & ΥΠΗΡΕΣΙΕΣ”

ΕΡΓΑΣΙΑ στο μάθημα

«Προγραμματισμός και Υποδομές Μεγάλων Δεδομένων: Python και Νεφοϋπολογιστική»

Δήμητρα Συκερίδη me25036

Μανώλης Κουργιαντάκης me25020

Μαριλένα Κασιούμη me 25016

Παντελής Αρβανιτάκης me 25003

Επιβλέπων Καθηγητής:

Νικόλαος Σγουρός

ΑΚΑΔ. ΕΤΟΣ 2025-2026

1. Εισαγωγή – Περιγραφή προβλήματος 3
2. Εισαγωγή – Περιγραφή δεδομένων 3
3. Συνοπτική περιγραφή του συστήματος που αναπτύχθηκε 4
4. Προεπεξεργασία Δεδομένων 5
5. Μεθοδολογία – Αναπαραγωγή του paper (Μέρος Α) 5
5.1 Μοντελοποίηση κρατήσεων ως “events” 5
5.2 Συχνότητα εμφάνισης και διάρκεια κράτησης 5
5.3 Σύγκριση ανά τύπο πλοίου – Detention Rate 6
5.4 Σύγκριση ανά τύπο πλοίου – Μέση διάρκεια κράτησης 7
6. Detention Defect Risk Matrix (Μέρος Α) 8
6.1 Οπτικοποίηση αποτελεσμάτων Risk Matrix 8
7. Ανάλυση συσχετίσεων – Association Rules (Μέρος Α) 9
7.1 Οπτικοποίηση δικτύων συσχέτισης 9
8. Κατάταξη κινδύνου ελλείψεων ανά τύπο πλοίου 10
9. Επέκταση με τεχνικές Μηχανικής Μάθησης (Μέρος Β) 10
9.1 Μετασχηματισμός δεδομένων για μηχανική μάθηση 12
9.2 Εφαρμογή Μεθόδου SHAP 12
9.3 Μείωση διαστάσεων με Principal Component Analysis (PCA) 13
9.4 Εκπαίδευση μοντέλου Random Forest 14
9.5 Υλοποίηση και Συγκριτική Αξιολόγηση Μοντέλου 14
9.6 Σημαντικότητα χαρακτηριστικών (Feature Importance) 16
9.7 Συνολική αποτίμηση της επέκτασης 16
10. Συμπεράσματα 16
11. Βιβλιογραφία 17

1. Εισαγωγή – Περιγραφή προβλήματος

Η ναυτιλία αποτελεί έναν από τους σημαντικότερους πυλώνες της παγκόσμιας οικονομίας, καθώς το μεγαλύτερο ποσοστό του διεθνούς εμπορίου μεταφέρεται μέσω θαλάσσης. Λόγω της κρισιμότητάς της, η διασφάλιση της ασφάλειας των πλοίων, των πληρωμάτων και του θαλάσσιου περιβάλλοντος διέπεται από αυστηρά διεθνή πρότυπα. Στο πλαίσιο της εφαρμογής αυτών των κανονισμών, τα κράτη εφαρμόζουν τον μηχανισμό Port State Control (PSC), μέσω του οποίου πραγματοποιούνται επιθεωρήσεις σε πλοία που προσεγγίζουν τα λιμάνια τους. Κατά τις επιθεωρήσεις αυτές εντοπίζονται ελλείψεις (deficiencies), οι οποίες μπορεί να αφορούν τεχνικά συστήματα, διαδικασίες ασφαλείας, έγγραφα ή συνθήκες διαβίωσης. Όταν οι ελλείψεις θεωρηθούν σοβαρές, το πλοίο μπορεί να τεθεί σε κράτηση (detention) μέχρι να αποκατασταθούν. Οι κρατήσεις αυτές συνεπάγονται σημαντικό οικονομικό κόστος και πλήγμα στη φήμη των ναυτιλιακών εταιρειών. Συνεπώς, η ανάλυση των δεδομένων PSC είναι ζωτικής σημασίας για την εκτίμηση και τη διαχείριση κινδύνου.

Η παρούσα εργασία βασίζεται στο επιστημονικό άρθρο *Risk analysis of ship detention defects based on association rules* και έχει ως στόχο:

- Την κατανόηση και αναπαραγωγή της προτεινόμενης μεθοδολογίας του paper.
- Την υλοποίησή της σε Python κάνοντας χρήση πραγματικών δεδομένων από το Paris MoU.
- Την ανάλυση των αποτελεσμάτων μέσω γραφημάτων και τεχνικής ερμηνείας.
- Την επέκταση της αρχικής προσέγγισης με τη χρήση αλγορίθμων Μηχανικής Μάθησης (Machine Learning), με σκοπό την ενίσχυση της προγνωστικής ικανότητας και τον ακριβέστερο εντοπισμό πλοίων υψηλού κινδύνου.

2. Περιγραφή δεδομένων

Τα δεδομένα που χρησιμοποιούνται στην παρούσα εργασία προέρχονται από το Paris MoU και περιλαμβάνουν 4045 εγγραφές κρατήσεων πλοίων για την περίοδο 2014–2020. Το Paris MoU αποτελεί έναν από τους σημαντικότερους οργανισμούς Port State Control (PSC) διεθνώς, καλύπτοντας μεγάλο μέρος των ευρωπαϊκών λιμένων, καθώς και άλλες συνεργαζόμενες χώρες. Η βάση δεδομένων του περιλαμβάνει λεπτομερείς πληροφορίες σχετικά με επιθεωρήσεις πλοίων, ελλείψεις και κρατήσεις, αποτελώντας σημαντική πηγή για ανάλυση κινδύνου και αξιολόγηση της ναυτιλιακής ασφάλειας.και διαθέτει εκτενή βάση δεδομένων επιθεωρήσεων.

Κάθε εγγραφή αποτελεί μια μοναδική περίπτωση επιθεώρησης που οδήγησε σε κράτηση και περιλαμβάνει κρίσιμες μεταβλητές όπως:

- τον τύπο του πλοίου,

- τις ελλείψεις που καταγράφηκαν κατά την επιθεώρηση
- τη διάρκεια της κράτησης , όπου αυτή επιβλήθηκε

Σύμφωνα με το paper, η ανάλυση επικεντρώνεται σε έξι βασικούς τύπους πλοίων. Οι έξι βασικοί τύποι αυτών των πλοίων είναι : General cargo , Bulk carrier, Container, Chemical tanker, Oil tanker και Ro-Ro cargo.

Οι ελλείψεις κατηγοριοποιούνται σε 17 βασικές ομάδες , σύμφωνα με την επίσημη ταξινόμηση του Paris MoU.

Οι 17 αυτές κατηγορίες είναι οι εξής: 'Certificates & Documentation', ,'Structural condition', 'Water/Weathertight condition' ,'Emergency Systems' ,'Radio communication', 'Cargo operations', 'Fire safety', 'Alarms', 'Working and Living Conditions', 'Safety of Navigation' ,'Life saving appliances', 'Dangerous Goods', 'Propulsion and auxiliary machinery', 'Pollution Prevention', 'ISM', 'MLC, 2006' και 'Other'.

Η ομαδοποίηση αυτή επιτρέπει την ανάλυση σε πιο γενικό επίπεδο, μειώνοντας τη διασπορά των δεδομένων και διευκολύνοντας την εξαγωγή στατιστικά σημαντικών συμπερασμάτων.

Κατά την προεπεξεργασία των δεδομένων πραγματοποιήθηκε αντιστοίχιση των ελλείψεων σε ενιαίους κωδικούς, ώστε να αποφεύγονται διπλοεγγραφές και ασυνέπειες. Ιδιαίτερη σημασία έχει το γεγονός ότι κάθε κράτηση αντιμετωπίζεται ως ξεχωριστό γεγονός (event), το οποίο μπορεί να περιλαμβάνει περισσότερες από μία ελλείψεις. Αυτή η προσέγγιση είναι κρίσιμη τόσο για τη σωστή στατιστική ανάλυση όσο και για την εφαρμογή association rules.

3. Συνοπτική περιγραφή του συστήματος που αναπτύχθηκε

Το σύστημα που αναπτύχθηκε στο πλαίσιο της εργασίας υλοποιήθηκε σε Python και ακολουθεί τη μεθοδολογία που περιγράφεται στο επιστημονικό άρθρο. Ο βασικός στόχος του συστήματος είναι η ανάλυση των δεδομένων κρατήσεων, η αξιολόγηση του κινδύνου που σχετίζεται με συγκεκριμένες κατηγορίες ελλείψεων και η ανακάλυψη συσχετίσεων μεταξύ αυτών.

Η ροή εργασιών (pipeline) ακολουθεί τρία διακριτά στάδια:

Στατιστική ανάλυση κρατήσεων και ελλείψεων: Σε αυτό το στάδιο πραγματοποιείται η βασική επεξεργασία των δεδομένων , η ομαδοποίηση των κρατήσεων και ο υπολογισμός βασικών στατιστικών μεγεθών , όπως η συχνότητα εμφάνισης κάθε κατηγορίας έλλειψης

Κατασκευή πίνακα αξιολόγησης κινδύνου (Detention Defect Risk Matrix): Με βάση τα στατιστικά στοιχεία, κατασκευάζεται ένας πίνακας αξιολόγησης κινδύνου, στον οποίο κάθε κατηγορία έλλειψης βαθμολογείται ανάλογα με την συχνότητα εμφάνισης και την σοβαρότητα της , όπως αυτή εκφράζεται μέσω της διάρκεια κρατήσεως.

Ανάλυση συσχετίσεων μεταξύ ελλείψεων με Association Rules: Στο τρίτο στάδιο εφαρμόζονται τεχνικές εξόρυξης συσχετίσεων με στόχο τον εντοπισμό συχνών συνδυασμών ελλείψεων που

εμφανίζονται στις κρατήσεις. Οι κανόνες συσχέτισης επιτρέπουν την αναγνώριση προτύπων κινδύνου και τη βαθύτερη κατανόηση των αιτιών που οδηγούν σε κρατήσεις πλοίων.

Η υλοποίηση πραγματοποιήθηκε σε περιβάλλον Jupyter Notebook, αξιοποιώντας βιβλιοθήκες όπως pandas, numpy και matplotlib για επεξεργασία και οπτικοποίηση, καθώς και εργαλεία εξόρυξης γνώσης για την ανάλυση συσχετίσεων.

4. Προεπεξεργασία Δεδομένων

Η διαδικασία προετοιμασίας των δεδομένων (ETL - Extract, Transform, Load) υπήρξε καθοριστική για την αξιοπιστία της ανάλυσης και περιέλαβε τα εξής βήματα:

- Συλλογή: Λήψη των μηνιαίων αναφορών κρατήσεων από το Paris MoU για την περίοδο 2014-2020 και ενοποίησή τους σε ένα ενιαίο σύνολο δεδομένων (dataset). Προστέθηκαν μεταδεδομένα (source_url, year_month) για τη διασφάλιση της πληρότητας των ετών.
- Καθαρισμός & Δόμηση: Τα αρχικά δεδομένα, που βρίσκονταν σε ημι-δομημένη μορφή, υπέστησαν επεξεργασία για τον διαχωρισμό των πραγματικών ελαττωμάτων από γενικά σχόλια. Εντοπίστηκαν οι στήλες περιγραφής (π.χ. *DefectiveItemDescr*), αφαιρέθηκαν εγγραφές με ελλιπή ή λανθασμένα στοιχεία (π.χ. αριθμητικές τιμές σε πεδία κειμένου) και απομακρύνθηκαν τα διπλότυπα.
- Κατηγοριοποίηση: Εφαρμόστηκε διαδικασία χαρτογράφησης (mapping) των χιλιάδων διαφορετικών περιγραφών ελαττωμάτων στους 17 τυποποιημένους κωδικούς του Paris MoU.
- Τελική Μορφοποίηση: Το καθαρό σύνολο δεδομένων αποθηκεύτηκε σε μορφή CSV, περιλαμβάνοντας μόνο τις κρίσιμες μεταβλητές (IMO, Τύπος Πλοίου, Κωδικός Ελαττώματος, Διάρκεια), έτοιμο για την εφαρμογή των αλγορίθμων.

5. Μεθοδολογία – Αναπαραγωγή του paper (Μέρος Α)

5.1 Μοντελοποίηση κρατήσεων ως “events”

Σύμφωνα με τη λογική του paper, κάθε κράτηση πλοίου αντιμετωπίζεται ως ένα ανεξάρτητο γεγονός (event). Για τον λόγο αυτό, τα δεδομένα ομαδοποιούνται έτσι ώστε κάθε κράτηση να περιλαμβάνει:

- τον τύπο του πλοίου,
- τη συνολική διάρκεια κράτησης,
- το σύνολο των κατηγοριών ελλείψεων που εντοπίστηκαν.

Αυτή η προσέγγιση επιτρέπει τον σωστό υπολογισμό της συχνότητας εμφάνισης κάθε κατηγορίας ελλείψεων και την εφαρμογή τεχνικών association rules.

5.2 Συχνότητα εμφάνισης και διάρκεια κράτησης

Στο πρώτο στάδιο της ανάλυσης υπολογίστηκαν το ποσοστό των κρατήσεων στις οποίες εμφανίζεται κάθε κατηγορία ελλείψεων (detention rate) και η μέση διάρκεια κράτησης που σχετίζεται με την κάθε κατηγορία. Τα αποτελέσματα παρουσιάζονται στο Figure 1, όπου οι μπάρες απεικονίζουν το ποσοστό κρατήσεων ανά κατηγορία, ενώ η γραμμή δείχνει τη μέση διάρκεια κράτησης (σε ημέρες).

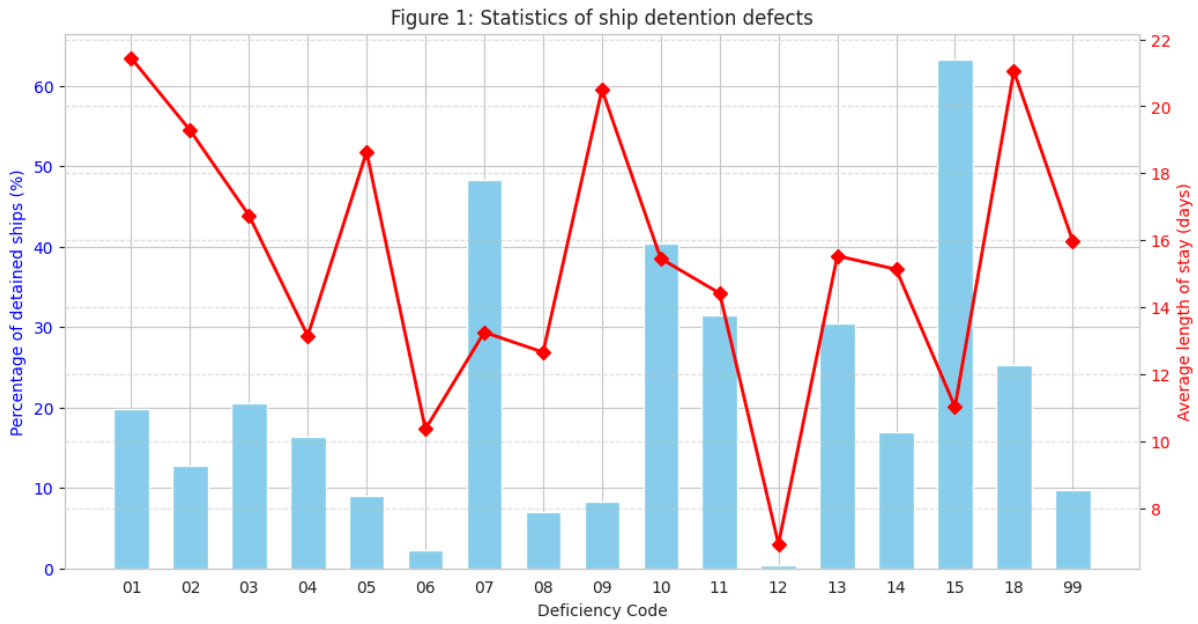

Εικόνα 1: Διαγραμματική απεικόνιση της διαδικασίας μετασχηματισμού των δεδομένων (Data Transformation). Τα πρωτογενή δεδομένα ελλείψεων ομαδοποιούνται σε μοναδικά περιστατικά κράτησης (Transaction Events), δημιουργώντας ένα διάνυσμα που περιλαμβάνει τον τύπο πλοίου, τη διάρκεια κράτησης και το σύνολο των κωδικών ελαττωμάτων.

Από το γράφημα παρατηρείται ότι ορισμένες κατηγορίες, όπως οι Fire safety, ISM και Safety of Navigation, εμφανίζονται με υψηλή συχνότητα στις κρατήσεις. Αντίθετα, κατηγορίες όπως το Working & Living Conditions, το Certificates & Documentation και το Structural Condition εμφανίζονται σπανιότερα, αλλά όταν εμφανιστούν οδηγούν σε μεγαλύτερης διάρκειας κρατήσεις. Το εύρημα αυτό δείχνει ότι η αξιολόγηση κινδύνου δεν μπορεί να βασίζεται μόνο στη συχνότητα, αλλά πρέπει να λαμβάνει υπόψη και τη διάρκεια.

5.3 Σύγκριση ανά τύπο πλοίου – Detention Rate

Στη συνέχεια, η ανάλυση επεκτάθηκε ανά τύπο πλοίου. Στο Figure 2 παρουσιάζεται το ποσοστό κρατήσεων ανά κατηγορία ελλείψεων για κάθε τύπο πλοίου.

Το γράφημα δείχνει ότι, παρότι οι γενικές τάσεις είναι παρόμοιες, υπάρχουν σημαντικές διαφορές μεταξύ τύπων πλοίων. Για παράδειγμα στα oil tankers και στα general cargo πλοία εμφανίζονται συχνότερα ελλείψεις σε Safety of Navigation, ενώ στα Ro-Ro cargo εμφανίζονται αυξημένα ποσοστά σε Fire safety και ISM.

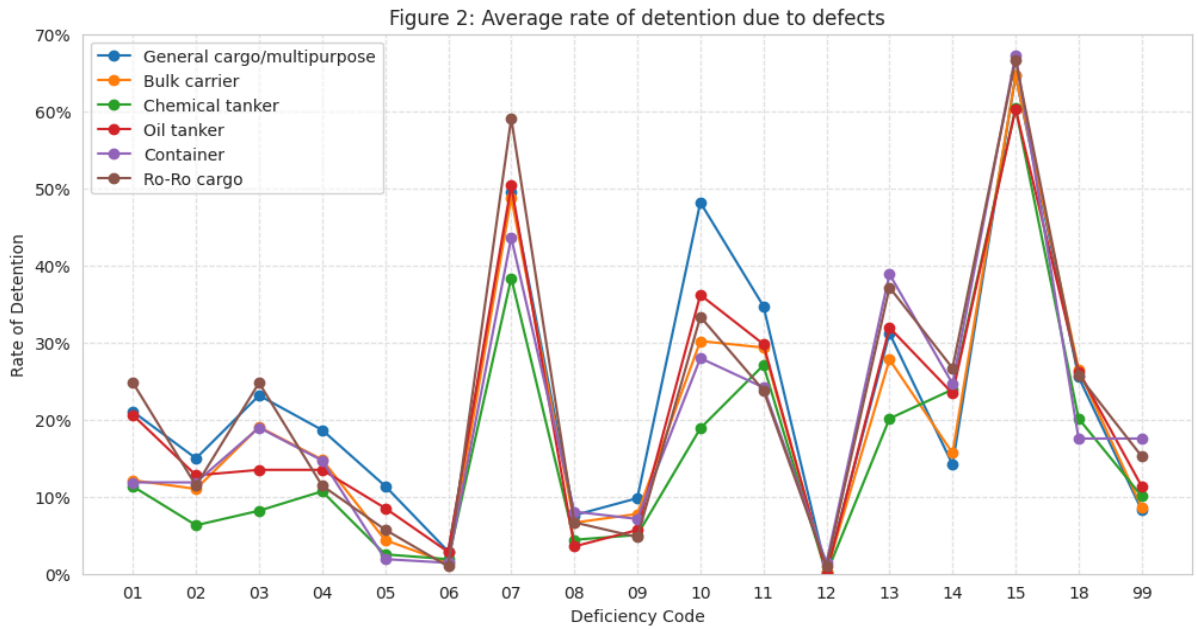

Εικόνα 2: *Διαγραμματική απεικόνιση του μέσου ποσοστού κρατήσεων (Average Rate of Detention) ανά κωδικό έλλειψης (Deficiency Code) για τους διαφορετικούς τύπους πλοίων. Στο γράφημα αποτυπώνονται οι διαφοροποιήσεις στη συχνότητα των κρατήσεων, αναδεικνύοντας τις κατηγορίες ελλείψεων που επηρεάζουν περισσότερο τον κάθε τύπο πλοίου.*

5.4 Σύγκριση ανά τύπο πλοίου – Μέση διάρκεια κράτησης

Το Figure 3 απεικονίζει τη μέση διάρκεια κράτησης ανά κατηγορία ελλείψεων και τύπο πλοίου.

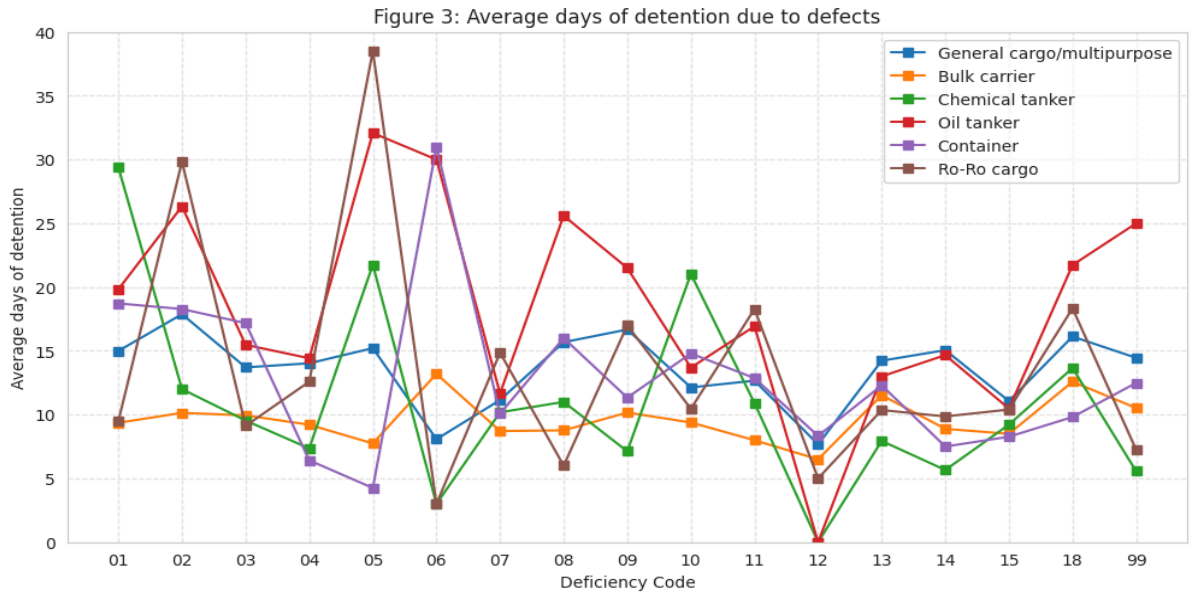

Εικόνα 3: *Διαγραμματική απεικόνιση της μέσης διάρκειας κράτησης (σε ημέρες) ανά κωδικό έλλειψης για τους διαφορετικούς τύπους πλοίων. Διακρίνονται οι κατηγορίες ελλείψεων που επιφέρουν τις πιο χρονοβόρες κρατήσεις.*

Το γράφημα δείχνει ότι τα oil tankers παρουσιάζουν γενικά μεγαλύτερη διάρκεια κράτησης, ενώ τα bulk carriers έχουν μικρότερη μέση διάρκεια. Επιπλέον, ορισμένες κατηγορίες ελλείψεων έχουν δυσανάλογα μεγάλη επίδραση στη διάρκεια κράτησης, γεγονός που δικαιολογεί τη χρήση risk matrix.

6. Detention Defect Risk Matrix (Μέρος Α)

Για την ολοκληρωμένη αξιολόγηση του κινδύνου, εφαρμόστηκε πίνακας Detention Defect Risk Matrix, όπως προτείνεται στο paper. Ο πίνακας αυτός συνδυάζει:

- την πιθανότητα κράτησης λόγω μιας έλλειψης,
- και τη μέση διάρκεια κράτησης που προκαλεί.

Οι δύο αυτές διαστάσεις κατηγοριοποιούνται σε πέντε επίπεδα και συνδυάζονται σε πίνακα 5×5, ο οποίος αποδίδει τελικό επίπεδο κινδύνου από πολύ χαμηλό έως πολύ υψηλό. Η διαδικασία εφαρμόζεται ξεχωριστά για κάθε τύπο πλοίου, ώστε να ληφθούν υπόψη οι ιδιαιτερότητές του.

6.1 Οπτικοποίηση αποτελεσμάτων Risk Matrix

Τα αποτελέσματα παρουσιάζονται στο Figure 4 μέσω τρισδιάστατου γραφήματος, όπου:

- ο άξονας x αντιστοιχεί στις κατηγορίες ελλείψεων,
- ο άξονας y στους τύπους πλοίων,
- και ο άξονας z στο επίπεδο κινδύνου.

Figure 4: Detention defect risk level

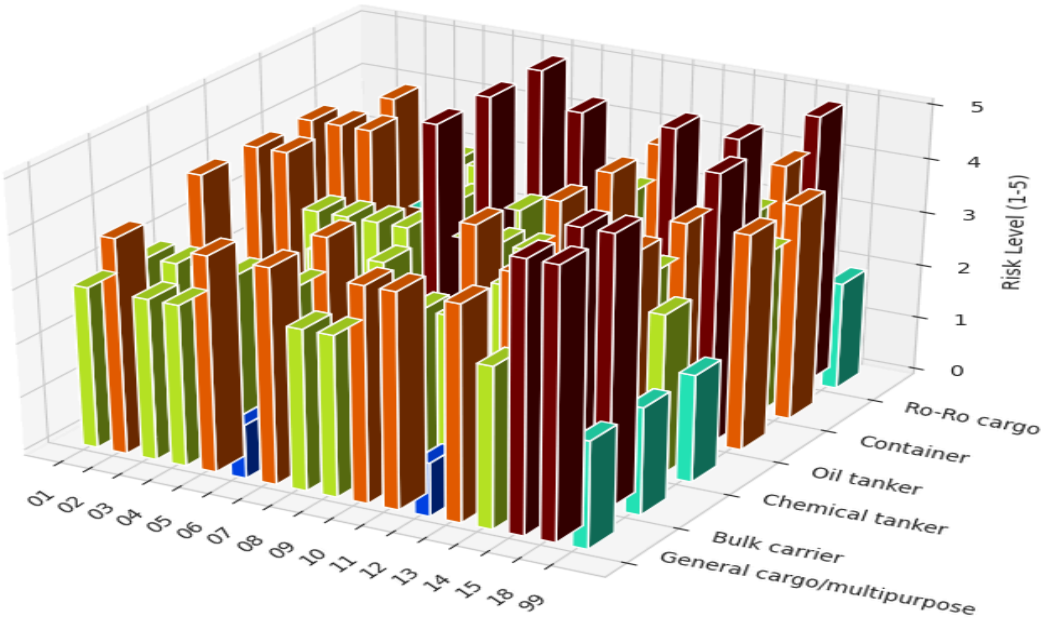

Εικόνα 4: *Τρισδιάστατη απεικόνιση του επιπέδου κινδύνου (Risk Level) που προκύπτει από τον πίνακα Risk Matrix, ανά κωδικό έλλειψης και τύπο πλοίου. Οι υψηλότερες στήλες (κόκκινο χρώμα) υποδεικνύουν τις κατηγορίες ελλείψεων με τη μεγαλύτερη βαρύτητα, συνδυάζοντας την πιθανότητα εμφάνισης με τη σοβαρότητα των επιπτώσεων στη διάρκεια κράτησης.*

Από το γράφημα προκύπτει ότι οι κατηγορίες ISM και Fire safety εμφανίζουν υψηλό κίνδυνο σχεδόν σε όλους τους τύπους πλοίων, ενώ άλλες κατηγορίες παρουσιάζουν αυξημένο κίνδυνο μόνο σε συγκεκριμένους τύπους πλοίων.

7. Ανάλυση συσχετίσεων – Association Rules (Μέρος Α)

Η ανάλυση association rules εφαρμόστηκε με στόχο να εντοπιστούν ομάδες ελλείψεων που εμφανίζονται συχνά μαζί στις κρατήσεις. Για την εξαγωγή ισχυρών κανόνων χρησιμοποιήθηκαν δείκτες support, confidence και lift. Η ανάλυση πραγματοποιήθηκε ξεχωριστά για κάθε τύπο πλοίου, ώστε να καταγραφούν οι διαφοροποιήσεις στα μοτίβα συσχέτισης.

7.1 Οπτικοποίηση δικτύων συσχέτισης

Τα αποτελέσματα παρουσιάζονται στο Figure 5 μέσω γραφημάτων δικτύου, όπου:

- οι κόμβοι αντιστοιχούν σε κατηγορίες ελλείψεων,
- και οι ακμές σε ισχυρούς κανόνες συσχέτισης.

Τα γραφήματα δείχνουν καθαρά ότι οι ελλείψεις ISM και Fire safety λειτουργούν συχνά ως “κεντρικοί κόμβοι”, δηλαδή εμφανίζονται σε συνδυασμό με πολλές άλλες ελλείψεις. Αυτό υποδηλώνει ότι η παρουσία τους αυξάνει σημαντικά την πιθανότητα πολλαπλών προβλημάτων και, κατ’ επέκταση, κράτησης.

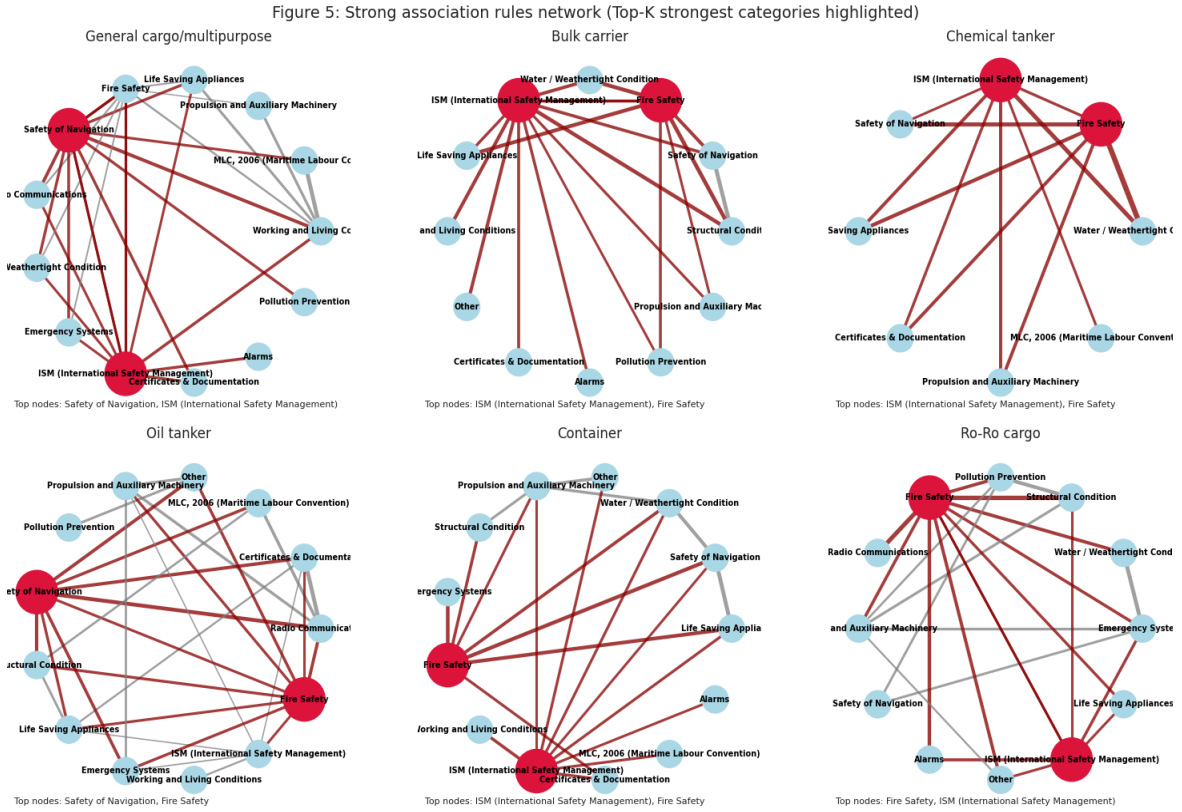

Εικόνα 5: *Οπτικοποίηση των δικτύων συσχέτισης (Association Rules Networks) για τους διαφορετικούς τύπους πλοίων. Οι κόμβοι αναπαριστούν κατηγορίες ελλείψεων, ενώ οι συνδέσεις (ακμές) υποδηλώνουν την ισχύ της συνύπαρξής τους. Οι «κεντρικοί κόμβοι» (μεγαλύτεροι και πιο έντονοι) αναδεικνύουν τις ελλείψεις που λειτουργούν ως πυρήνες προβλημάτων, όπως το ISM και το Fire Safety.*

8. Κατάταξη κινδύνου ελλείψεων ανά τύπο πλοίου

Για τη συνοπτική αποτύπωση του κινδύνου, δημιουργήθηκε κατάταξη των κατηγοριών ελλείψεων ανά τύπο πλοίου, βασισμένη στο επίπεδο κινδύνου που προέκυψε από το Risk Matrix. Η κατάταξη αυτή παρουσιάζεται στο Figure 6 μέσω radar charts.

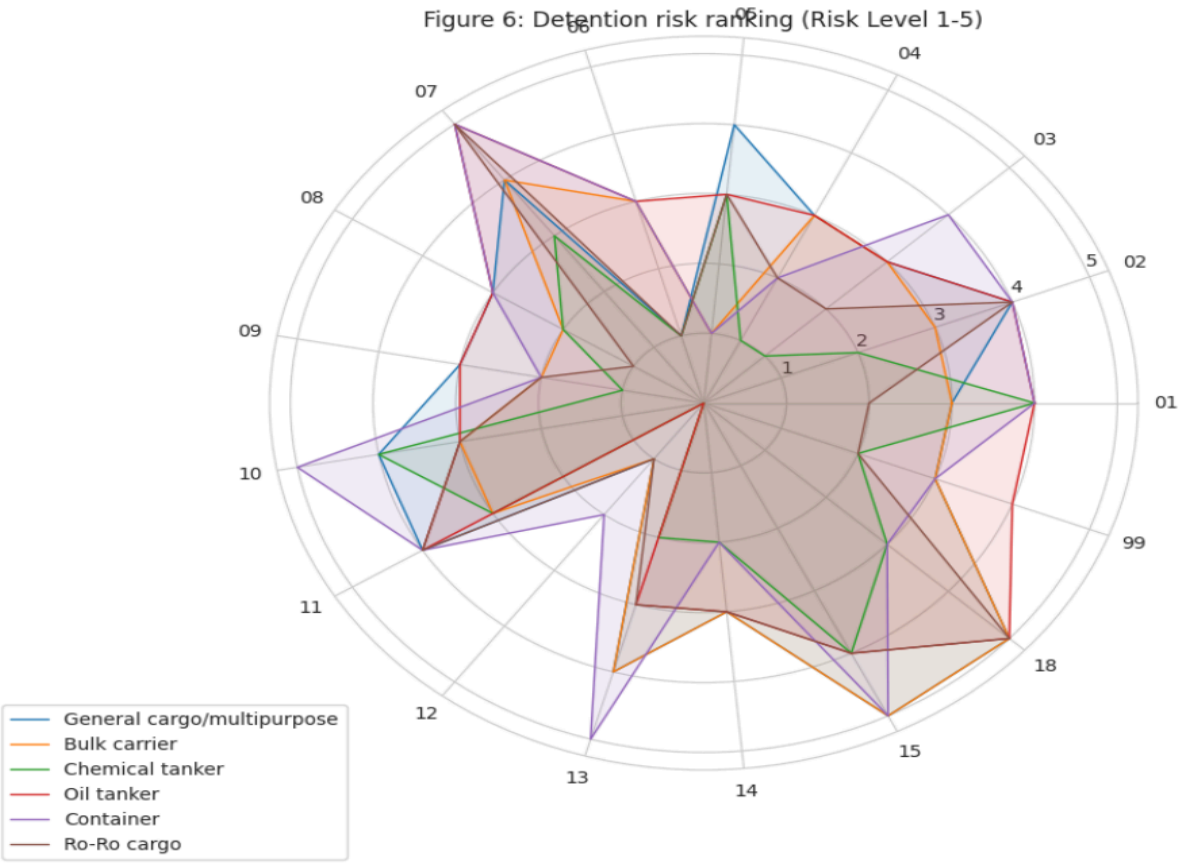

Εικόνα 6: *Απεικόνιση της κατάταξης κινδύνου (Risk Ranking) μέσω διαγράμματος αράχνης (radar chart). Συγκρίνονται τα προφίλ επικινδυνότητας των διαφορετικών τύπων πλοίων βάσει των επιπέδων κινδύνου (1-5) για κάθε κατηγορία έλλειψης.*

Τα γραφήματα δείχνουν με σαφή τρόπο ποιες κατηγορίες ελλείψεων αποτελούν τον μεγαλύτερο κίνδυνο για κάθε τύπο πλοίου, διευκολύνοντας τη συγκριτική αξιολόγηση.

9. Επέκταση με τεχνικές Μηχανικής Μάθησης (Μέρος Β)

Στο πλαίσιο της επέκτασης της εργασίας εφαρμόστηκαν τεχνικές μηχανικής μάθησης με στόχο τη διερεύνηση της δυνατότητας πρόβλεψης κινδύνου κράτησης. Συγκεκριμένα:

- Εκπαιδεύτηκε μοντέλο Random Forest στο αρχικό σύνολο χαρακτηριστικών και πραγματοποιήθηκε ανάλυση ερμηνευσιμότητας με την μέθοδο SHAP,
- Εφαρμόστηκε Principal Component Analysis (PCA) για μείωση διαστάσεων,
- Εκπαιδεύτηκε μοντέλο Random Forest,
- Πραγματοποιήθηκε ρύθμιση υπερ παραμέτρων με Grid Search.

9.1 Μετασχηματισμός δεδομένων για μηχανική μάθηση

Για την εφαρμογή αλγορίθμων μηχανικής μάθησης, τα δεδομένα μετασχηματίστηκαν σε μορφή κατάλληλη για εποπτευόμενη μάθηση. Κάθε κράτηση πλοίου αναπαρίσταται ως μία εγγραφή, με χαρακτηριστικά που περιγράφουν:

- την παρουσία ή απουσία συγκεκριμένων κατηγοριών ελλείψεων,
- τον τύπο του πλοίου,
- καθώς και συνοπτικές πληροφορίες που προκύπτουν από τη διάρκεια κράτησης.

Οι κατηγορίες ελλείψεων μετατράπηκαν σε δυαδικές μεταβλητές (0/1), γεγονός που επιτρέπει στο μοντέλο να "δει" ποιοι συνδυασμοί ελλείψεων εμφανίζονται σε κάθε κράτηση. Με αυτόν τον τρόπο, η πληροφορία που χρησιμοποιείται στις association rules αξιοποιείται και στο πλαίσιο της μηχανικής μάθησης.

9.2 Εφαρμογή Μεθόδου SHAP

Μέθοδος Ανάλυσης SHAP

Η μέθοδος SHAP εφαρμόστηκε στο μοντέλο χωρίς PCA ,ώστε να διατηρηθεί η ερμηνευσιμότητα. Οι διαστάσεις των SHAP δεδομένων ταυτίστηκαν πλήρως με τον αριθμό χαρακτηριστικών του μοντέλου, ενώ τα αποτελέσματα ήταν σταθερά και οι εξηγήσεις συμφωνούν με την λογική των ελέγχων Port State Control.

Η μέθοδος SHAP καταδεικνύει ως σημαντικότερους παράγοντες που σχετίζονται με υψηλή διάρκεια κράτησης τις παρακάτω ελλείψεις :

- Ελλείψεις σε Propulsion and auxiliary machinery
- Ελλείψεις σε MLC, 2006
- Ελλείψεις σε Safety of Navigation
- Ελλείψεις σε Water/Weathertight condition
- Ελλείψεις σε Structural condition
- Ελλείψεις σε Certificates & Documentation

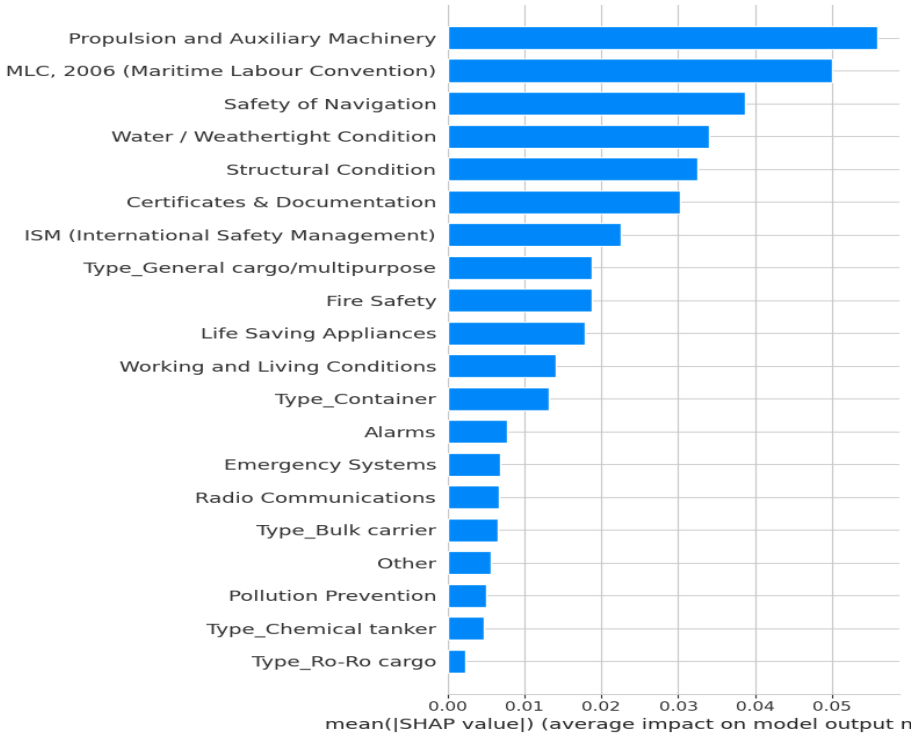

Εικόνα 7: *Ραβδόγραμμα καθολικής σημαντικότητας χαρακτηριστικών (Global Feature Importance) βάσει των μέσων απόλυτων τιμών SHAP. Το μήκος κάθε ράβδου υποδεικνύει τη μέση επίδραση που έχει η κάθε κατηγορία έλλειψης στη διαμόρφωση της τελικής πρόβλεψης του μοντέλου.*

Πιο αναλυτικά, οι ελλείψεις με βάση την κατηγορία Propulsion and Auxiliary Machinery καταδεικνύεται ως ο ισχυρότερος παράγοντας πρόβλεψης υψηλού ρίσκου. Οι μηχανικές βλάβες τείνουν να επηρεάζουν άμεσα την ασφάλεια και λειτουργικότητα του πλοίου. Στις περισσότερες περιπτώσεις, υποδεικνύουν σοβαρά τεχνικά προβλήματα. Επόμενη κατηγορία που σχετίζεται με υψηλή διάρκεια κράτησης εμφανίζεται η MLC, 2006 , η οποία σχετίζεται με πιθανή ένδειξη γενικότερης κακής διαχείρισης του πλοίου. Στην συνέχεια, υψηλά εμφανίζεται και η κατηγορία Safety of Navigation , η οποία συνδέεται άμεσα με κινδύνους ασφάλειας και συμβαδίζει με τις προτεραιότητες των PSC ελέγχων.

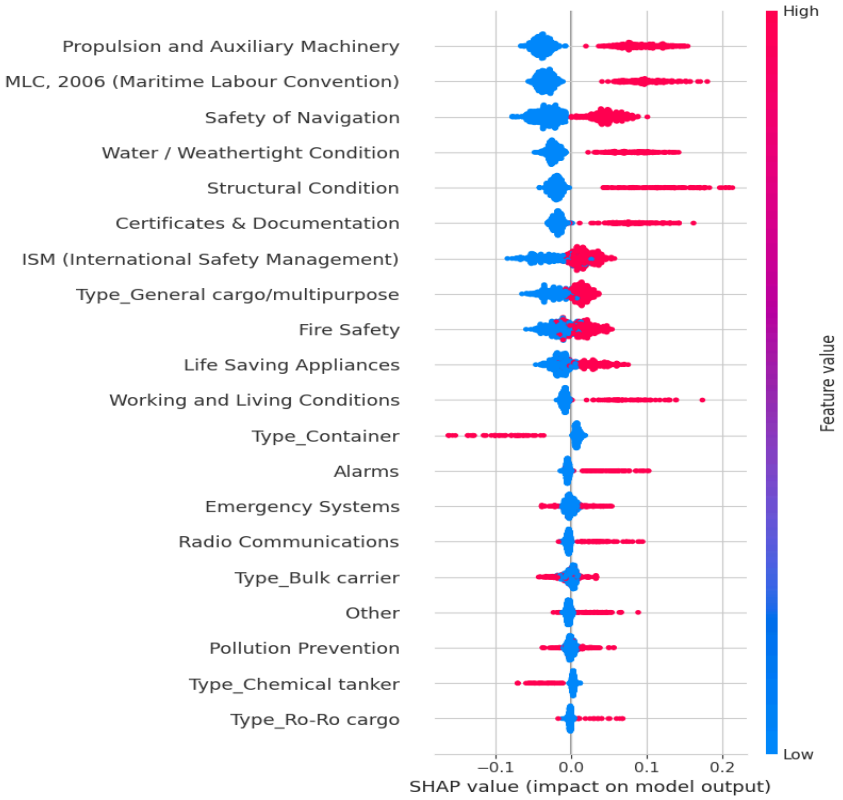

Εικόνα 8: *Διάγραμμα σύνοψης SHAP (Summary Plot). Κάθε σημείο αντιπροσωπεύει ένα δείγμα, με το χρώμα να υποδηλώνει την τιμή του χαρακτηριστικού (κόκκινο = υψηλή, μπλε = χαμηλή). Η θέση στον οριζόντιο άξονα δείχνει αν η επίδραση στην πρόβλεψη κινδύνου είναι θετική (δεξιά) ή αρνητική (αριστερά).*

Αναφορικά με την επίδραση του τύπου των πλοίων, τα πλοία με τύπο container εμφανίζουν χαμηλότερη συνεισφορά προς υψηλό ρίσκο. Πιθανολογείται πως αυτό συμβαίνει λόγω καλύτερης κουλτούρας συμμόρφωσης, συνήθως μεγαλύτερες εταιρείες διαθέτουν τέτοιους τύπους πλοίων και αντίστοιχα πιο δομημένες διαδικασίες ελέγχων με αυστηρότερα πρότυπα ασφάλειας. Τα bulk carriers παρουσίασαν μεγαλύτερη μεταβλητότητα, πιθανώς λόγω ηλικίας στόλου ή συντήρησης.

Η ανάλυση των τιμών SHAP δείχνει πως τα δυαδικά χαρακτηριστικά σχηματίζουν δύο σαφώς διακριτές ομάδες τιμών. Η παρουσία μιας έλλειψης αυξάνει την πιθανότητα το περιστατικό να χαρακτηριστεί ως High Risk, ενώ η απουσία της την μειώνει. Η συμπεριφορά αυτή θεωρείται αναμενόμενη και αποτελεί καλή ‘ένδειξη βαθμονόμησης του μοντέλου. Τα αποτελέσματα αυτά δείχνουν πως οι σοβαρές τεχνικές ναυτιλιακές ελλείψεις συνδέονται με μεγαλύτερη διάρκεια κρατήσεων ,ενώ ζητήματα που αφορούν το πλήρωμα λειτουργούν επίσης ως σημαντικοί δείκτες κινδύνου. Επιπλέον, διαπιστώνεται ότι ο τύπος πλοίου επηρεάζει το προφίλ κινδύνου.

9.3 Μείωση διαστάσεων με Principal Component Analysis (PCA)

Λόγω του σχετικά μεγάλου αριθμού χαρακτηριστικών (πολλές κατηγορίες ελλείψεων), εφαρμόστηκε Principal Component Analysis (PCA) με στόχο:

- τη μείωση της διαστασιμότητας,
- τη μείωση του θορύβου,
- και τη βελτίωση της γενίκευσης των μοντέλων.

Τα αποτελέσματα της PCA έδειξαν ότι ένα μικρό σύνολο κύριων συνιστωσών μπορεί να εξηγήσει σημαντικό ποσοστό της συνολικής διακύμανσης των δεδομένων. Αυτό υποδηλώνει ότι οι ελλείψεις δεν λειτουργούν ανεξάρτητα αλλά σχηματίζουν ομάδες με παρόμοια πληροφορία, κάτι που είναι σύμφωνο με τα αποτελέσματα της ανάλυσης association rules.Η PCA, επομένως, επιβεβαιώνει από διαφορετική σκοπιά ότι υπάρχουν υποκείμενες δομές και συσχετίσεις στα δεδομένα PSC.

9.4 Εκπαίδευση μοντέλου Random Forest

Στη συνέχεια εκπαιδεύτηκε μοντέλο Random Forest, το οποίο επιλέχθηκε λόγω της ικανότητάς του να χειρίζεται μη γραμμικές σχέσεις, της ανθεκτικότητάς του στον θόρυβο και της δυνατότητας εξαγωγής σημαντικότητας χαρακτηριστικών (feature importance). Το μοντέλο εκπαιδεύτηκε με στόχο να διαχωρίσει κρατήσεις υψηλότερου και χαμηλότερου κινδύνου, αξιοποιώντας τα χαρακτηριστικά που προέκυψαν από τις ελλείψεις και τον τύπο πλοίου.Η διαδικασία εκπαίδευσης συνοδεύτηκε από:

- διαχωρισμό δεδομένων σε σύνολο εκπαίδευσης και ελέγχου,
- και ρύθμιση υπερπαραμέτρων μέσω Grid Search, ώστε να επιλεγεί ο βέλτιστος συνδυασμός.

9.5 Υλοποίηση και Συγκριτική Αξιολόγηση Μοντέλου

— Μεθοδολογία Εκπαίδευσης και Μείωση Διαστάσεων

Για την ανάπτυξη του μοντέλου πρόβλεψης, υλοποιήθηκε Pipeline που περιλάμβανε κανονικοποίηση δεδομένων (StandardScaler), μείωση διαστάσεων μέσω PCA και ταξινόμηση με Random Forest. Στο στάδιο του PCA, επιλέχθηκε η διατήρηση του 95% της διακύμανσης, γεγονός που οδήγησε στη συμπίεση των αρχικών χαρακτηριστικών σε μόλις 21 κύριες συνιστώσες. Η δραστική αυτή μείωση επιβεβαιώνει ότι η πληροφορία στα δεδομένα PSC μπορεί να κωδικοποιηθεί αποδοτικά, αφαιρώντας τον θόρυβο.

— Αναλυτικά Αποτελέσματα Μοντέλου (με PCA)

Μέσω Grid Search, το μοντέλο βελτιστοποιήθηκε με max_depth=10 και 200 εκτιμητές. Η αξιολόγηση στο Test Set (σύνολο 967 εγγραφών) έδωσε τα εξής αποτελέσματα:

- ➔ Ακρίβεια (Accuracy): 63.2%
- ➔ F1-Score (Weighted Avg): 0.631

Αναλυτικότερα ανά κλάση:

- ➔ Κλάση 0 (Low Risk - Support: 509): Precision: 0.643, Recall: 0.676, F1-score: 0.659
- ➔ Κλάση 1 (High Risk - Support: 458): Precision: 0.618, Recall: 0.583, F1-score: 0.600

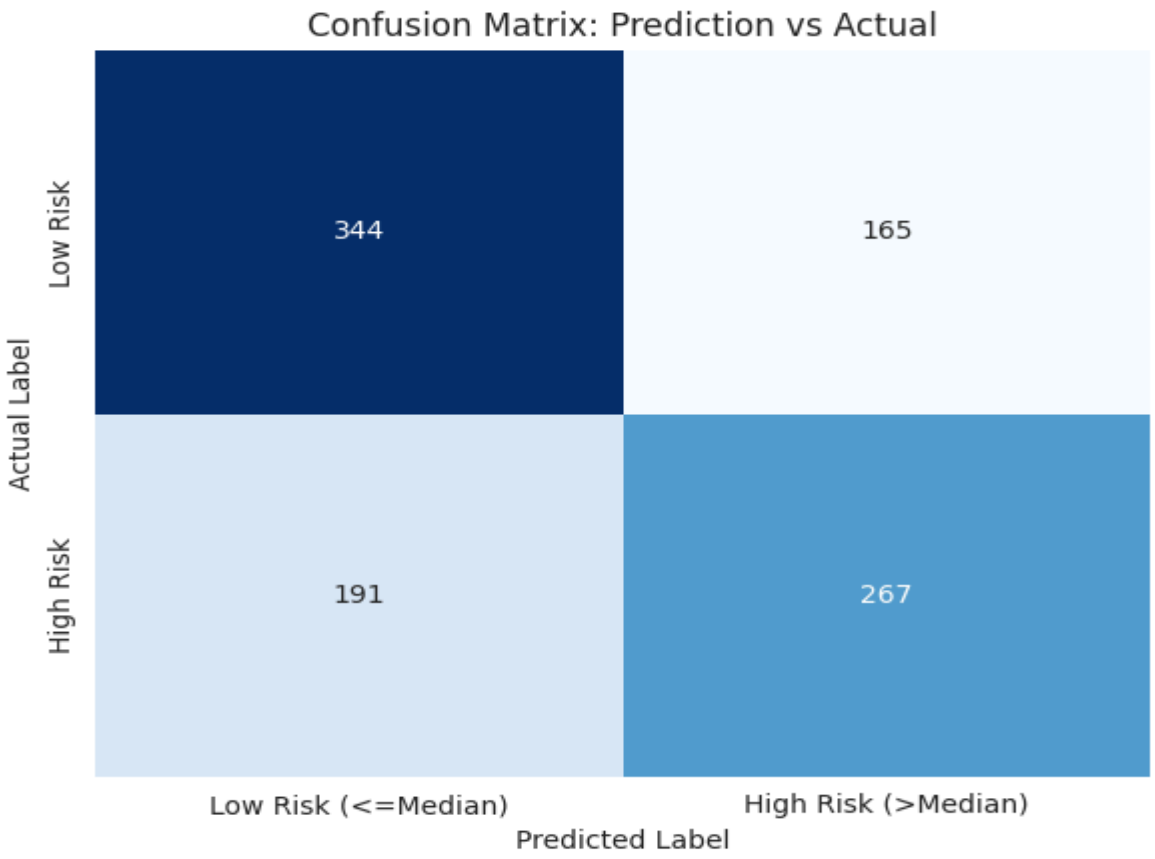

Εικόνα 9: *Πίνακας Σύγχυσης (Confusion Matrix) και μετρικές αξιολόγησης του βέλτιστου μοντέλου Random Forest (με PCA) στο σύνολο ελέγχου. Στον πίνακα διακρίνονται οι σωστές προβλέψεις (κύρια διαγώνιος: 344 Low Risk, 267 High Risk) έναντι των λανθασμένων ταξινομήσεων.*

— Συγκριτική Αξιολόγηση (Χωρίς PCA)

Για λόγους σύγκρισης, εκπαιδεύτηκε μοντέλο στο πλήρες σύνολο χαρακτηριστικών. Το μοντέλο αυτό πέτυχε ελαφρώς υψηλότερη ακρίβεια (64.2%) και Weighted F1-Score (0.641). Ωστόσο, για να επιτύχει αυτή τη μικρή βελτίωση (+1%), το μοντέλο αναγκάστηκε να αυξήσει την πολυπλοκότητά του, επιλέγοντας διπλάσιο βάθος δέντρου (max_depth=20).

Τα αποτελέσματα ανά κλάση ήταν:

- ➔ Κλάση 0: Precision: 0.652, Recall: 0.688, F1-score: 0.669
- ➔ Κλάση 1: Precision: 0.630, Recall: 0.592, F1-score: 0.610

— Συμπέρασμα

Η συγκριτική ανάλυση καθιστά την προσέγγιση με PCA σαφώς προτιμητέα. Η οριακή αύξηση της απόδοσης στο μοντέλο χωρίς PCA δεν δικαιολογεί τον διπλασιασμό της πολυπλοκότητας (Depth 20), γεγονός που αποτελεί ισχυρή ένδειξη υπερπροσαρμογής (overfitting) στα δεδομένα εκπαίδευσης. Αντιθέτως, το μοντέλο με PCA (Depth 10) επιτυγχάνει παρεμφερή προβλεπτική ικανότητα με πολύ λιγότερες παραμέτρους, διασφαλίζοντας μεγαλύτερη στιβαρότητα (robustness) και καλύτερη ικανότητα γενίκευσης σε νέα δεδομένα

9.6 Σημαντικότητα χαρακτηριστικών (Feature Importance)

Ένα ιδιαίτερα χρήσιμο αποτέλεσμα της επέκτασης είναι η ανάλυση της σημαντικότητας των χαρακτηριστικών από το μοντέλο Random Forest. Τα χαρακτηριστικά που εμφανίζονται ως πιο σημαντικά είναι κατηγορίες ελλείψεων που έχουν ήδη αναδειχθεί ως υψηλού κινδύνου μέσω του Risk Matrix, όπως οι ελλείψεις ISM, Fire safety και Safety of Navigation.
Το εύρημα αυτό είναι ιδιαίτερα σημαντικό, διότι επιβεβαιώνει τα αποτελέσματα της αρχικής αναλυτικής μεθοδολογίας και δείχνει ότι τα ίδια χαρακτηριστικά είναι κρίσιμα τόσο σε αναλυτικό όσο και σε προβλεπτικό επίπεδο. Με άλλα λόγια, το μοντέλο "μαθαίνει" μόνο του τη σημασία ελλείψεων που ήδη έχουν αναδειχθεί μέσω της ανάλυσης κινδύνου και των association rules.

9.7 Συνολική αποτίμηση της επέκτασης

Συνολικά, η επέκταση με τεχνικές μηχανικής μάθησης επιβεβαιώνει τη σημασία των βασικών ελλείψεων που αναδείχθηκαν στο Μέρος Α, δείχνει ότι τα δεδομένα PSC περιέχουν επαρκή πληροφορία για προβλεπτική ανάλυση και ενισχύει τη συνολική αξιοπιστία της αρχικής μεθοδολογίας. Η προσέγγιση αυτή ανταποκρίνεται στις απαιτήσεις της εκφώνησης για ουσιαστική επέκταση και προσθέτει τεχνική αξία στην εργασία.

10. Συμπεράσματα

Η παρούσα εργασία κατέδειξε ότι η συστηματική ανάλυση δεδομένων Port State Control μπορεί να προσφέρει ουσιαστική και τεκμηριωμένη εκτίμηση του κινδύνου κράτησης πλοίων. Μέσω της αναπαραγωγής της μεθοδολογίας του επιστημονικού άρθρου και της υλοποίησής της σε Python, κατέστη δυνατή η ανάπτυξη ενός ολοκληρωμένου πλαισίου που συνδυάζει περιγραφική στατιστική, πίνακα αξιολόγησης κινδύνου (Risk Matrix) και ανάλυση συσχετίσεων μέσω της τεχνικής association rules. Το πλαίσιο αυτό προσφέρει μια ολοκληρωμένη εικόνα των ελλείψεων και της επίδρασής τους. Η πολυδιάστατη προσέγγιση, η οποία λαμβάνει υπόψη τόσο τη συχνότητα εμφάνισης ελλείψεων όσο και τη διάρκεια κράτησης, ανέδειξε κρίσιμες κατηγορίες όπως οι ISM, Fire Safety και Safety of Navigation, ως βασικούς δείκτες αυξημένου κινδύνου, αναδεικνύοντας παράλληλα διαφοροποιήσεις μεταξύ των τύπων πλοίων.

Η εφαρμογή association rules αποκάλυψε ότι οι ελλείψεις εμφανίζονται συχνά σε επαναλαμβανόμενα μοτίβα, υποδηλώνοντας την ύπαρξη υποκείμενων συστημικών αδυναμιών. Σε συνέχεια της αναλυτικής προσέγγισης, στο προβλεπτικό στάδιο, το μοντέλο Random Forest, σε συνδυασμό με PCA και SHAP, έδειξε ότι τα δεδομένα PSC μπορούν να υποστηρίξουν αξιόπιστη ταξινόμηση περιστατικών υψηλού και χαμηλού κινδύνου, διατηρώντας παράλληλα ερμηνευσιμότητα και ισορροπία μεταξύ απόδοσης και

πολυπλοκότητας. Συνολικά, η εργασία επιβεβαιώνει ότι ο συνδυασμός αναλυτικών και προβλεπτικών τεχνικών αποτελεί μια συνεκτική, τεχνικά τεκμηριωμένη και εφαρμοσμένη προσέγγιση για τη διαχείριση ναυτιλιακού κινδύνου.

Μελλοντικά, η ανάλυση θα μπορούσε να εμπλουτιστεί με επιπλέον χαρακτηριστικά, όπως ηλικία πλοίου, σημαία, οργανισμός κλάσης, ιστορικό προηγούμενων επιθεωρήσεων ή γεωγραφικά δεδομένα λιμένων, ώστε να αποτυπωθεί με μεγαλύτερη ακρίβεια το προφίλ κινδύνου. Η ενσωμάτωση χρονοσειρών θα επέτρεπε τη μελέτη της εξέλιξης της συμμόρφωσης στο χρόνο, την ανίχνευση τάσεων και την έγκαιρη αναγνώριση αυξημένου κινδύνου.

Επιπλέον, θα μπορούσαν να δοκιμαστούν πιο σύνθετα μοντέλα πρόβλεψης, όπως Gradient Boosting ή νευρωνικά δίκτυα, καθώς και τεχνικές ανισόρροπης μάθησης σε περίπτωση ανισορροπίας μεταξύ των κλάσεων. Η ανάπτυξη ενός διαδραστικού dashboard ή ενός συστήματος υποστήριξης αποφάσεων σε πραγματικό χρόνο θα μπορούσε να μετατρέψει τα αποτελέσματα της έρευνας σε επιχειρησιακό εργαλείο για ναυτιλιακές εταιρείες και ρυθμιστικές αρχές, ενισχύοντας τη στρατηγική πρόληψη και τη βελτιστοποίηση των ελέγχων.

11. Βιβλιογραφία

1. Lundberg, S. M., & Lee, S. I. (2017). A Unified Approach to Interpreting Model Predictions.
2. Yang, Z., et al. (2018). *A new ship risk assessment model for port state control.*
3. *Yan, R., & Wang, S. (2019). Data-driven ship detention probability prediction network.*